



拉格朗日乘子理解、对偶方法介绍

目录

Contents



1

方法理解

2

最优控制

3

对偶观点

方法理解

方法理解

最优控制

对偶观点

拉格朗日乘数法是最优化问题求解中, **处理约束**(等式, 不等式) 的常见思路

Primal Problem:

$$\begin{aligned} & \min f_0(x) \\ \text{s. t. } & \begin{cases} f_i(x) \leq 0, i = 1, \dots, m \\ h_i(x) = 0, i = 1, \dots, p \end{cases} \end{aligned}$$



Lagrangian:

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

$\lambda_i \geq 0$ 称作第 i 个不等式的拉格朗日乘子, $v_i \cdots$ 第 i 个等式



Optimal Condition (equations):

$$\frac{\partial L}{\partial x_i} = 0$$

And other KKT conditions...



方法理解

方法理解

最优控制

对偶观点

第一种理解方式: 可行方向与下降方向线性相关.

考虑如下 n 元 m 约束最优化问题.

Primal Problem:

$$\begin{aligned} \min f(x) \\ \text{s.t. } g(x) = 0 \end{aligned}$$



Lagrangian Function:

$$L(x, \lambda, \nu) = f(x) + \lambda^T g(x)$$

这里 λ 称作等式的拉格朗日乘子

设最优解为 x^*

- 在 x^* 附近的**可行方向**集合为: $\{\Delta x: \nabla g(x^*)^T \Delta x = 0\}$
- 沿可行方向, **目标函数不再下降**: $f(x^* + \epsilon \Delta x) \approx f(x^*) + \nabla f(x^*)^T \Delta x + \epsilon \geq f(x^*)$

以上表明: 对任意可行方向, $\nabla f(x^*)^T \Delta x = 0$. 从而 $\nabla f = \lambda^T \nabla g$, 即 $\nabla_x L = 0$ (n 个方程). 结合已有的 m 个等式约束, 构成了 $m + n$ 等式/约束方程, 理论上可解.

Remark: λ 只是梯度线性相关的一种表示, L 没有具体物理含义.



方法理解

方法理解

最优控制

对偶观点

第二种理解方式: 惩罚函数

Primal Problem:

$$\begin{aligned} & \min f_0(x) \\ \text{s.t. } & \begin{cases} f_i(x) \leq 0, i = 1, \dots, m \\ h_i(x) = 0, i = 1, \dots, p \end{cases} \end{aligned}$$



Lagrangian:

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

$\lambda_i \geq 0$ 称作第 i 个不等式的拉格朗日乘子, $v_i \cdots$ 第 i 个等式

原问题等价于:

$$\min_x \max_{\lambda, v} L(x, \lambda, v)$$

Proof: 在给定 x 的前提下, 考虑 λ, v 的最佳取值

- 当 x 在可行域中时, $v_i h_i(x) = 0, \lambda_i f_i(x) \leq 0, \forall \lambda_i \geq 0, v_i \in R$. 这表明最佳取值下 $\lambda_i f_i(x) = v_i h_i(x) = 0$. 从而此时 $\max_{\lambda, v} L(x, \lambda, v) = f_0(x)$
- 当 $h_i(x) \neq 0$ 时, $\max_{\lambda, v} L(x, \lambda, v) = L(x, \lambda, \infty \times \text{sgn}(h_i(x))) = +\infty$
- 当 $f_i(x) > 0$ 时, $\max_{\lambda, v} L(x, \lambda, v) = L(x, +\infty, v) = +\infty$

方法理解

方法理解

最优控制

对偶观点

第二种理解方式: 惩罚函数

Primal Problem:

$$\begin{aligned} & \min f_0(x) \\ \text{s. t. } & \begin{cases} f_i(x) \leq 0, i = 1, \dots, m \\ h_i(x) = 0, i = 1, \dots, p \end{cases} \end{aligned}$$



Lagrangian:

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x)$$

$\lambda_i \geq 0$ 称作第 i 个不等式的拉格朗日乘子, $v_i \cdots$ 第 i 个等式

若 L 关于 x, λ, v 连续, 且各决策变量均连续, 则

$$\min_x \max_{\lambda, v} L(x, \lambda, v)$$

最优解一定满足 $\nabla_x L = 0$.

Remark: λ, v 定义为惩罚因子, 但当 $f_i(x) = 0$ 或 $h_j(x) = 0$ 时, 惩罚项均为0, λ, v 可以任意取.



方法理解

方法理解

最优控制

对偶观点

基于惩罚函数的举例

举例:

$$\begin{aligned} \min_x & x^2 \\ \text{s.t. } & x^2 \leq 1 \end{aligned}$$

$$L = x^2 + \lambda(x^2 - 1), \lambda \geq 0$$

对于 $\min_x \max_{\lambda} L$:

$$\lambda = \begin{cases} +\infty, & x^2 > 1 \\ 0, & x^2 < 1 \\ \text{任意}, & x^2 = 1 \end{cases}$$

原问题划为

$$\min \bar{f}(x)$$

其中

$$\bar{f}(x) = \begin{cases} x^2, & x^2 \leq 1 \\ +\infty, & \text{else} \end{cases}$$

目录

Contents



1

方法理解

2

最优控制

3

对偶观点

最优控制

方法理解

最优控制

对偶观点

变分法中的等式约束

优化目标	$\min_x f(x)$ $s. t. h(x) = 0$	$\min_x \int_{t_0}^{t_f} g(x, \dot{x}, t) dt$ $s. t. f(x, \dot{x}, t) = 0$
拉格朗日函数	$L := f + \lambda^T h$	$L := \int_{t_0}^{t_f} g + \lambda(t) f dt$
等价命题	$\min_x \max_{\lambda} L$	$\min_x \max_{\lambda} L$
必要条件	$\nabla_x L = \nabla_{\lambda} L = 0$	$\delta_x L = \delta_{\lambda} L = 0$
数量与索引	有限个 λ , 以 i 为下标	无限个 λ , 以 t 为索引

Remark: 拉格朗日乘子可以处理不等式约束, 可否类比到变分法中处理不等式约束? 有兴趣者可以自行探索.

目录

Contents



1

方法理解

2

最优控制

3

对偶观点

对偶观点

方法理解

最优控制

对偶观点

Review: 拉格朗日乘子/函数的两个理解角度:

$$L = f(x) + \lambda^T h(x)$$


- 梯度角度: $\nabla_x L = 0$. 缺陷: L 本身无含义, 其他 λ 无含义.
- 惩罚角度: $\min_x \max_{\lambda} L$. 缺陷: $h(x) = 0$ 时, λ 可任意取(实际能求出唯一值).
- 对偶角度:

$$\text{Dual Prob} \rightarrow \max_{\lambda} \min_x L \leq \min_x \max_{\lambda} L \leftarrow \text{Primal Prob}$$

Proof:

对于任意一点 (x_0, λ_0) , 有

$$L(x^*, \lambda_0) = \min_x L(x, \lambda_0) \leq L(x_0, \lambda_0) \leq \max_{\lambda} L(x_0, \lambda) = L(x_0, \lambda^*)$$

假设左边最优在 (x_1, λ_1) 取得, 右边最优在 (x_2, λ_2) 取到, 则由下图可知命题成立.

对偶观点

方法理解

最优控制

对偶观点

构建对偶问题

$$\begin{aligned} & \min f_0(x) \\ \text{s. t. } & \begin{cases} f_i(x) \leq 0, i = 1, \dots, m \\ h_i(x) = 0, i = 1, \dots, p \end{cases} \end{aligned}$$

$$\bar{f}(x) = \max_{\lambda \geq 0, v} \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)$$

$$g(\lambda, v) = \min_x \left(f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p v_i h_i(x) \right)$$

Primal problem:

$$\min_x \bar{f}(x)$$

Dual problem:

$$\max_{\lambda \geq 0, v} g(\lambda, v)$$

$$g(\lambda, v) \leq \max_{\lambda, v} g(\lambda, v) \leq \min_x \bar{f}(x) \leq \bar{f}(x)$$

- 对任意 λ, v , $g(\lambda, v)$ 提供了原问题最优解的一个下界, 而 $g(\lambda^*, v^*)$ 提供了最优下界.
- 若 $\max_{\lambda, v} g(\lambda, v) = \min_x f(x)$, 则 $f_0(x^*) = g(\lambda^*, v^*) \leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*) \leq f_0(x^*)$ 说明上面两个不等号取等.

注: *代表最优解.



对偶观点

方法理解

最优控制

对偶观点

KKT条件、正则项

续上页:

根据

$$\begin{aligned} f_0(x^*) &= g(\lambda^*, v^*) \\ &\leq f_0(x^*) + \sum_{i=1}^m \lambda_i^* f_i(x^*) + \sum_{i=1}^p v_i^* h_i(x^*) \\ &\leq f_0(x^*) \end{aligned}$$

这说明:

$$\lambda_i^* f_i(x^*) = 0, \forall i = 1, \dots, m$$

以及

$$L(\lambda^*, v^*, x^*) = \inf_x L(\lambda^*, v^*, x)$$

表明 $L(\lambda^*, v^*, x)$ 在 $x = x^*$ 处导数为0:

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0$$

Remark1:

由此得到完整的KKT条件(不严谨表述)

$$\begin{aligned} f_i(x^*) &\leq 0, \\ h_i(x^*) &= 0, \\ \lambda_i^* &\geq 0, \\ \lambda_i^* f_i(x^*) &= 0, \end{aligned}$$

$$\nabla f_0(x^*) + \sum_{i=1}^m \lambda_i^* \nabla f_i(x^*) + \sum_{i=1}^p v_i^* \nabla h_i(x^*) = 0$$

Remark2:

后者表明, 原问题的最优解也是无约束优化问题

$$\min_x L(\lambda^*, v^*, x)$$

的最优解, 这表明, 先选择合适的 λ, v , 原最优化问题可以近似转化为无约束优化问题.

谢谢观看